

UNIVERSIDADE FEDERAL DA PARAÍBA
LENHS/UFPB

Material didático de apoio ao minicurso
Documento 02

SISTEMA DE CONTROLE PID SOBRE PLANTA SUBSTITUTA
BASEADA EM REDE NEURAL ARTIFICIAL

Arquitetura da malha, lei de controle, critérios de desempenho e procedimentos de sintonia

João Pessoa
2026

RESUMO

Este documento apresenta o sistema de controle de pressão em malha fechada desenvolvido para a planta de distribuição de água do LENHS/UFPB. O controlador Proporcional-Integral-Derivativo (PID) atua sobre a frequência do inversor que aciona a bomba centrífuga, com o objetivo de manter a pressão medida em PT_4A próxima de um valor de referência. Como a planta física não está disponível para simulação contínua, emprega-se um modelo substituto (*surrogate model*) baseado em Rede Neural Artificial. São discutidos a lei de controle, sua implementação incremental com saturação, os critérios de desempenho adotados, as limitações físicas que restringem a sintonia e os procedimentos de ajuste automático e de otimização dos ganhos.

Palavras-chave: controle PID; controle de pressão; modelo substituto; rede neural artificial; sintonia de controladores.

1 INTRODUÇÃO

O sistema de controle tem por objetivo manter a pressão medida em PT_4A próxima de um valor de referência, denominado *setpoint*, atuando sobre a frequência do inversor que aciona a bomba centrífuga. Configura-se, assim, um problema de controle de pressão em malha fechada, típico de estações de bombeamento e de sistemas de distribuição de água. A descrição física da planta encontra-se no Documento 01, e a obtenção dos dados e do modelo neural, no Documento 03.

2 ARQUITETURA DA MALHA DE CONTROLE

Na malha de controle, o *setpoint* é comparado com a pressão medida, gerando um sinal de erro. Esse erro alimenta o controlador PID, cuja saída, a frequência do inversor, é aplicada à planta. A pressão resultante é então realimentada para uma nova comparação com o *setpoint*, fechando a malha.

Como a planta física real não está disponível para simulação contínua, ela é substituída por um modelo substituto (*surrogate model*): a Rede Neural Artificial treinada no script RNA.py e armazenada no arquivo Modelo_AI_v1.h5. Esse modelo recebe a frequência e as demais variáveis medidas da rede e retorna a pressão prevista em PT_4A. Do ponto de vista do controlador, a RNA comporta-se como uma caixa-preta: recebe o sinal de controle e devolve a medição.

3 CONTROLADOR PID

3.1 Lei de controle

O controlador implementa a lei PID clássica, segundo a qual o sinal de controle é obtido pela soma de três parcelas: a parcela proporcional, dada pelo ganho K_p multiplicado pelo erro atual; a parcela integral, dada pelo ganho K_i multiplicado pela integral do erro ao longo do tempo; e a parcela derivativa, dada pelo ganho K_d multiplicado pela taxa de variação do erro. O erro é definido como a diferença entre o *setpoint* e a pressão medida.

3.2 Implementação incremental e saturação

A saída do controlador é aplicada de forma incremental sobre a frequência do passo anterior, ou seja, o valor do sinal de controle no instante atual corresponde ao valor do instante anterior acrescido da ação de controle calculada no instante atual.

O sinal resultante é submetido a saturação no intervalo de 0 a 100, o mesmo *clamping* genérico empregado nos scripts Graph.py e teste.py. Esse intervalo foi mantido deliberadamente, em vez da faixa física real do inversor, de 0 a 50 Hz. O motivo é que, como as demais 12 variáveis de entrada da RNA permanecem congeladas no estado de uma amostra real, o modelo responde pouco à variação isolada da frequência dentro da faixa de 0 a 50 Hz, e a simulação só convergiu, nos *setpoints* testados, quando a entrada pôde extrapolar valores acima de 50. Por essa razão, o valor da variável “Inversor” utilizado internamente na simulação não deve ser interpretado como uma frequência fisicamente executável pelo inversor real.

3.3 Critérios de desempenho

Os ganhos K_p , K_i e K_d foram ajustados por tentativa e erro, na mesma forma utilizada em `Graph.py` e `teste.py`, observando-se três critérios de desempenho. O primeiro é o sobressinal, ou *overshoot*, que corresponde ao máximo desvio da resposta além do *setpoint*, expresso em porcentagem. O segundo é o tempo de acomodação, que corresponde ao tempo necessário para que a resposta permaneça dentro de uma faixa de tolerância em torno do *setpoint*. O terceiro é o erro em regime permanente, que corresponde à diferença residual entre o *setpoint* e a pressão após o término do transitório.

Complementarmente, foram considerados os índices de erro acumulado ISE, IAE e ITAE. O ISE (*Integral of Squared Error*) é a integral do quadrado do erro ao longo do tempo e penaliza fortemente erros de grande amplitude. O IAE (*Integral of Absolute Error*) é a integral do valor absoluto do erro e pondera igualmente todos os desvios. O ITAE (*Integral of Time-weighted Absolute Error*) é a integral do valor absoluto do erro multiplicado pelo tempo e penaliza sobretudo os erros que persistem ao final da resposta.

4 LIMITAÇÕES QUE ORIENTAM O AJUSTE DOS GANHOS

Dois fatores observados na planta restringem o grau de agressividade admissível para o controlador. O primeiro é o atraso hidráulico: a resposta em pressão não é instantânea à mudança de frequência, e ganhos elevados tendem a excitar esse atraso, gerando oscilação e sobressinal em torno do *setpoint*. O segundo é a perturbação causada pela válvula CV_4A: como a abertura da válvula não é uma entrada manipulada pelo PID, ela atua como perturbação de carga sobre o sistema, deslocando o ponto de operação da bomba independentemente da ação do controlador.

5 PROCEDIMENTOS DE SINTONIA AUTOMÁTICA

5.1 Iteração de ajuste automático

Na função de simulação `planta_pid`, caso o sobressinal resultante ultrapasse 30%, os ganhos K_p e K_d são reduzidos automaticamente pelo fator 0,7, e a simulação é repetida até que o critério seja atendido ou que se atinja um número máximo de tentativas. Esse procedimento prioriza a estabilidade em detrimento da velocidade de resposta.

5.2 Otimização por varredura em grade

Um segundo modo de operação, de otimização, realiza uma varredura em grade (*grid search*) sobre valores de K_p , K_i e K_d e seleciona a combinação que minimiza o índice ISE.